

1 — Description du projet

Auteur : Ahmed Ben Arfa
Projet : Tunisia Weather Prediction
Date : juillet 2026

1. Contexte

La Tunisie s'étend sur près de 900 km du nord au sud, du littoral méditerranéen aux portes du Sahara. Cette étendue produit des régimes climatiques très différents d'un gouvernorat à l'autre : sur la période étudiée, le cumul de précipitations annuel moyen va de **525 mm à Bizerte à 83 mm à Tozeur**, soit un rapport de 1 à 6. La température moyenne varie de 17,0 °C au Kef à 22,8 °C à Tozeur.

Prévoir la température à court terme a une valeur pratique directe : planification agricole et irrigation, dimensionnement de la production solaire, anticipation des vagues de chaleur, gestion de la demande énergétique.

Ce projet construit une chaîne analytique complète sur ce sujet, de l'extraction des données jusqu'à une application web déployée.

2. Objectif

Prévoir la **température à t+1 h, t+24 h et t+72 h** pour chacun des 24 gouvernorats, à partir de l'état météorologique observé jusqu'à l'instant courant.

Trois horizons plutôt qu'un seul, parce que la comparaison entre eux est elle-même un résultat : elle montre comment la prévisibilité se dégrade avec le temps, et à partir de quand un modèle statistique cesse d'apporter quelque chose face à une simple moyenne climatique.

3. Ce qui distingue ce projet des précédents

Les deux projets antérieurs traitaient des problèmes de **classification sur données transversales** — churn client, risque cardiaque. Ici il s'agit d'une **régression sur série temporelle**, ce qui change la méthode sur trois points non négociables :

Point	Classification transversale	Série temporelle
Découpage	Aléatoire stratifié	Chronologique strict
Fuite de données	Variables encodant la cible	Variables postérieures à l'instant de prédiction
Référence	Classe majoritaire, tirage au hasard	Persistance, climatologie, ARIMA
Structure	Observations indépendantes	24 séries parallèles, fortement corrélées

Un découpage aléatoire placerait des observations futures dans l'entraînement et produirait des scores flatteurs mais faux. Un modèle qui utiliserait la température ressentie au même instant que la cible afficherait un R^2 proche de 0,99 sans rien prédire du tout.

Ces pièges sont faciles à commettre et difficiles à repérer après coup. Les éviter — et montrer comment — constitue une part importante de la valeur du projet.

4. Périmètre fonctionnel

4.1 Extraction et préparation

Extraire l'historique horaire des 24 gouvernorats depuis Open-Meteo, contrôler sa qualité, le convertir dans un format exploitable et versionnable.

Particularité : **les données ont été extraites par l'équipe projet**, elles n'ont pas été fournies. Cela ajoute au périmètre la conception de la stratégie d'extraction, la gestion des quotas de l'API et la vérification de l'intégrité du jeu obtenu.

4.2 Entrepôt et modèle dimensionnel

Construire un schéma en étoile dans DuckDB — fait horaire, fait journalier agrégé, dimensions gouvernorat et temps — et alimenter Supabase avec la seule partie utile à l'application déployée.

4.3 Restitution descriptive

Produire un rapport Power BI sur la climatologie tunisienne : profils mensuels, contrastes régionaux, extrêmes, précipitations.

4.4 Data mining — dimension spatiale

Regrouper les gouvernorats par profil climatique via ACP et K-means. Le regroupement obtenu alimente ensuite les modèles prédictifs.

4.5 Séries temporelles — dimension temporelle

Décomposer les séries (tendance, saisonnalités, résidu), tester la stationnarité, et analyser l'autocorrélation. L'autocorrélation partielle sert directement à **justifier le choix des décalages** utilisés en modélisation, au lieu de les poser par intuition.

Trois modèles statistiques en progression — ARIMA, puis SARIMA à période diurne, puis régression harmonique de Fourier avec erreurs ARIMA — qui deviennent des concurrents à part entière des modèles de machine learning.

4.6 Machine learning

Construire les variables explicatives sans fuite temporelle, comparer plusieurs familles de modèles à trois horizons, les évaluer face aux baselines naïves et aux modèles statistiques, puis retenir le meilleur.

Un **modèle global** par horizon est entraîné sur les 24 gouvernorats empilés, plutôt que 24 modèles locaux : le volume d'entraînement est vingt-quatre fois supérieur, la physique atmosphérique apprise est commune, et les spécificités locales restent portées par la latitude, l'altitude et le groupe climatique.

4.7 Application web

Déployer une application où l'utilisateur choisit un gouvernorat et un horizon, reçoit une prévision calculée à partir de données fraîches, et peut la comparer à la prévision publiée par Open-Meteo.

5. Critères de succès

Critère	Seuil
Le modèle bat la meilleure baseline à t+1 h	Gain en MAE mesurable
Le modèle bat la meilleure baseline à t+24 h	Gain net et documenté
Le modèle bat la meilleure baseline à t+72 h	Gain net, ou constat argumenté de son absence
Absence de fuite temporelle	Vérifiée par construction et par l'écart validation/test
Cohérence entraînement / production	Écart mesuré et variables filtrées en conséquence
Reproductibilité	Pipeline ré-exécutable depuis le dépôt seul

Ces seuils seront chiffrés dès que les baselines auront été mesurées en phase 4, et reportés ici. La barre de t+1 h sera la plus sévère : battre la persistance à une heure suppose de faire mieux que « la température ne change pas en une heure », ce qui est déjà une excellente approximation.

Le troisième critère mérite une précision : **si le modèle ne bat pas la climatologie à 72 h, ce n'est pas un échec du projet.** C'est un résultat, et il devra être présenté comme tel plutôt que masqué. La prévision à trois jours relève de la modélisation physique de l'atmosphère, pas de la régression sur historique.

6. Livrables

Livrable	Format	Contenu
Code source	Dépôt GitHub public	Scripts, notebooks, application, données Parquet, documentation
Application déployée	URL publique	Interface de prévision fonctionnelle
Rapport	PDF	Démarche, architecture, choix techniques, résultats, limites
Présentation	Slides	Synthèse et démonstration

7. Hors périmètre

- **Concurrencer la prévision numérique du temps.** Open-Meteo s'appuie sur des modèles physiques à assimilation de données, alimentés par des observations mondiales. L'objectif ici est de démontrer une démarche complète et rigoureuse, pas de rivaliser avec l'état de l'art opérationnel.
- **Prévoir d'autres variables que la température.** Précipitations et vent restent exploités en analyse descriptive, sans modèle prédictif dédié.
- **Descendre sous la maille du gouvernorat.** Chaque gouvernorat est représenté par un point unique.