

2 — Description des données

Auteur : Ahmed Ben Arfa
Projet : Tunisia Weather Prediction
Date : juillet 2026

Toutes les statistiques de ce document sont calculées sur le jeu réel ([data/tunisia_weather_hourly.parquet](#)), pas reprises d'une documentation externe.

1. Provenance

Les données n'ont pas été fournies : elles ont été **extraites par l'équipe projet** depuis [Open-Meteo](#), via l'API d'archive [archive-api.open-meteo.com/v1/archive](#).

Cette API restitue la **réanalyse ERA5** du ECMWF, produite dans le cadre du programme européen Copernicus. Une réanalyse n'est pas un relevé de station : c'est la sortie d'un modèle atmosphérique qui assimile les observations disponibles pour reconstituer un état cohérent de l'atmosphère sur une grille régulière. Les valeurs sont donc physiquement cohérentes entre elles, mais ne correspondent pas exactement à ce qu'aurait mesuré un thermomètre à un endroit précis.

Licence : [CC BY 4.0](#) — usage libre avec attribution.

2. Volumétrie

Caractéristique	Valeur
Lignes	1 585 728
Colonnes	36
Gouvernorats	24
Pas de temps	Horaire
Période	2019-01-01 00:00 → 2026-07-15 23:00
Heures par gouvernorat	66 072 (2 753 jours)
Fuseau	Africa/Tunis
Valeurs manquantes	0
Doublons (gouvernorat, heure)	0

La série est **parfaitement continue** : sur les 66 071 intervalles d'un gouvernorat, tous valent exactement une heure. Aucun trou, aucune heure dupliquée. La Tunisie n'appliquant pas l'heure d'été, il n'y a pas non plus d'artefact de changement d'heure.

3. Couverture géographique

Chaque gouvernorat est représenté par les coordonnées de son chef-lieu. Les latitudes et longitudes du jeu final sont celles du **point de grille ERA5 le plus proche**, pas celles demandées.

Gouvernorat	Latitude	Longitude	Altitude (m)
Bizerte	37,293	9,788	5
Ariana	36,872	10,184	9

Gouvernorat	Latitude	Longitude	Altitude (m)
Tunis	36,801	10,171	11
Manouba	36,801	10,053	28
Beja	36,731	9,213	247
Ben Arous	36,731	10,276	8
Jendouba	36,520	8,824	145
Zaghouan	36,450	10,104	172
Nabeul	36,450	10,692	11
Kef	36,169	8,766	637
Siliana	36,098	9,339	431
Sousse	35,817	10,568	32
Monastir	35,747	10,786	29
Kairouan	35,677	10,077	64
Mahdia	35,536	10,976	6
Kasserine	35,185	8,839	674
Sidi Bouzid	35,044	9,504	333
Sfax	34,763	10,709	11
Gafsa	34,411	8,830	299
Tozeur	33,919	8,080	50
Gabes	33,849	10,087	10
Kebili	33,708	8,944	43
Medenine	33,357	10,556	92
Tataouine	32,935	10,478	238

L'altitude va de 5 m (Bizerte) à 674 m (Kasserine), amplitude suffisante pour peser sur les températures.

4. Dictionnaire des variables

36 colonnes : 31 mesures météorologiques, plus **gouvernorat**, **time**, **latitude**, **longitude**, **elevation**.

Statistiques calculées sur l'ensemble des 1 585 728 lignes.

Température et humidité de l'air

Variable	Unité	Min	Moy	Max
temperature_2m	°C	−3,60	19,88	50,20
apparent_temperature	°C	−7,80	18,77	47,60
dew_point_2m	°C	−17,90	10,59	27,10
relative_humidity_2m	%	4,00	60,89	100,00
vapour_pressure_deficit	kPa	0,00	1,22	11,89

temperature_2m est la **cible** du projet.

Précipitations

Variable	Unité	Min	Moy	Max
precipitation	mm	0,00	0,04	21,00
rain	mm	0,00	0,04	21,00
snowfall	cm	0,00	0,0002	1,96

Pression

Variable	Unité	Min	Moy	Max
pressure_msl	hPa	983,30	1016,86	1038,80
surface_pressure	hPa	914,70	999,55	1036,90

Nébulosité

Variable	Unité	Min	Moy	Max
cloud_cover	%	0	33,88	100
cloud_cover_low	%	0	8,61	100
cloud_cover_mid	%	0	12,77	100
cloud_cover_high	%	0	23,03	100

Vent

Variable	Unité	Min	Moy	Max
wind_speed_10m	km/h	0,00	12,21	74,00
wind_speed_100m	km/h	0,00	19,43	108,30
wind_gusts_10m	km/h	0,70	25,74	130,70
wind_direction_10m	°	0	191,57	360
wind_direction_100m	°	0	192,22	360

Les directions sont **circulaires** : 0° et 360° désignent le même nord. Une moyenne arithmétique n'a donc aucun sens sur ces colonnes, et un modèle qui les traiterait comme des nombres ordinaires apprendrait une discontinuité fictive entre 359° et 1°. Un encodage sinus/cosinus est nécessaire si elles sont utilisées.

Sol

Variable	Unité	Min	Moy	Max
soil_temperature_0_to_7cm	°C	-2,30	21,39	57,50
soil_temperature_7_to_28cm	°C	4,30	21,28	40,50
soil_temperature_28_to_100cm	°C	8,80	21,16	33,90
soil_moisture_0_to_7cm	m³/m³	-0,013	0,16	0,54
soil_moisture_7_to_28cm	m³/m³	-0,012	0,17	0,52
soil_moisture_28_to_100cm	m³/m³	-0,011	0,15	0,51

L'amplitude des températures de sol décroît nettement avec la profondeur (59,8 °C en surface contre 25,1 °C entre 28 et 100 cm) : le sol profond filtre les variations rapides et porte l'inertie thermique saisonnière. C'est un signal potentiellement utile pour la prévision.

Rayonnement

Variable	Unité	Min	Moy	Max
shortwave_radiation	W/m ²	0	212,32	1012,00
direct_radiation	W/m ²	0	145,01	829,00
diffuse_radiation	W/m ²	0	67,31	502,00
direct_normal_irradiance	W/m ²	0	237,55	936,40
terrestrial_radiation	W/m ²	0	349,43	1302,90
et0_fao_evapotranspiration	mm	0,00	0,18	1,31

Identification et géographie

Variable	Type	Description
gouvernorat	catégorie	Nom du gouvernorat (24 modalités)
time	datetime	Horodatage horaire, fuseau Africa/Tunis
latitude	float	Latitude du point de grille
longitude	float	Longitude du point de grille
elevation	float	Altitude du point de grille (m)

5. Contrastes climatiques observés

Température moyenne par gouvernorat

Du plus frais au plus chaud, avec les extrêmes atteints :

Gouvernorat	Min	Moy	Max
Kef	−3,4	17,0	44,0
Kasserine	−3,6	17,7	44,4
Beja	−1,6	18,3	46,8
Siliana	−1,6	18,5	45,2
Zaghouan	0,4	19,0	47,1
Nabeul	3,1	19,2	42,7
Ariana	1,2	19,3	48,3
Bizerte	4,9	19,4	46,9
Tunis	0,7	19,4	48,5
Manouba	0,3	19,5	48,7
Ben Arous	1,2	19,5	48,0
Jendouba	−0,5	19,6	48,2
Sidi Bouzid	−3,0	19,7	47,5
Mahdia	2,7	20,0	48,3
Sousse	0,9	20,1	48,6
Monastir	2,4	20,2	49,8
Sfax	2,2	20,4	46,2
Gafsa	−1,8	20,6	46,3
Kairouan	−1,0	20,9	50,2
Tataouine	2,3	21,0	47,1
Gabes	1,8	21,2	47,5
Medenine	1,5	21,6	48,4

Gouvernorat	Min	Moy	Max
Kebili	−0,8	22,2	48,9
Tozeur	−0,3	22,8	49,1

Le classement n'est pas purement latitudinal : Kef et Kasserine, les plus frais, sont aussi les plus élevés (637 m et 674 m). L'altitude compte autant que la position nord-sud.

Bizerte présente le minimum le plus doux (4,9 °C) malgré sa position la plus au nord — effet modérateur de la mer. À l'inverse, Sidi Bouzid et Kasserine descendent sous −3 °C : continentalité et altitude produisent des nuits froides que le littoral ne connaît pas.

Précipitations annuelles moyennes (2019-2025)

Gouvernorat	mm/an	Gouvernorat	mm/an
Bizerte	525	Kairouan	268
Ben Arous	434	Sidi Bouzid	217
Beja	432	Sfax	212
Jendouba	415	Gabes	158
Kef	410	Medenine	136
Tunis	402	Gafsa	135
Siliana	402	Tataouine	124
Ariana	399	Kebili	89
Zaghouan	390	Tozeur	83
Manouba	385		
Nabeul, Mahdia, Monastir, Sousse, Kasserine	272-350		

Le gradient nord-sud est le fait structurant du jeu : **un rapport de 1 à 6** entre Bizerte et Tozeur. C'est ce contraste que le clustering de la phase `04_data_mining` doit faire ressortir.

6. Qualité des données

Le jeu ne présente **aucune valeur manquante ni doublon**, et sa continuité horaire est parfaite. Trois points méritent néanmoins d'être signalés.

6.1 Humidité du sol négative

`soil_moisture_*` descend à **−0,013 m³/m³**, ce qui est physiquement impossible : une teneur en eau volumique ne peut pas être négative.

Couche	Lignes concernées	Part
soil_moisture_0_to_7cm	493	0,031 %
soil_moisture_7_to_28cm	460	0,029 %
soil_moisture_28_to_100cm	428	0,027 %

Les cas se concentrent sur les gouvernorats arides — Tozeur, Kebili, Gabes, Medenine, Tataouine, Gafsa, Sidi Bouzid, Sfax. Il s'agit d'un artefact numérique de la réanalyse sur sols très secs, où la valeur oscille autour de zéro. L'ampleur est négligeable (0,03 %) et la correction évidente : tronquer à zéro lors du nettoyage.

6.2 rain quasi redondante avec precipitation

Les deux colonnes ne diffèrent que sur **144 lignes** — exactement celles où `snowfall > 0`. Leur corrélation atteint 0,99976.

Conserver les deux dans un modèle introduirait une colinéarité quasi parfaite sans apport d'information. `precipitation` suffit ; `rain` et `snowfall` ne gardent un intérêt que pour distinguer les épisodes neigeux, rarissimes et cantonnés aux gouvernorats élevés du nord-ouest.

6.3 Points de grille partagés

Trois paires de gouvernorats partagent la même latitude de grille : Tunis/Manouba, Beja/Ben Arous, Zaghouan/Nabeul. Leurs longitudes diffèrent, les points restent donc distincts — mais cela rappelle que la résolution ERA5 (~9 km après post-traitement) ne sépare pas finement des chefs-lieux voisins.

Pour le Grand Tunis en particulier — Tunis, Ariana, Ben Arous, Manouba — les quatre points sont si proches que leurs séries sont fortement corrélées. C'est à garder en tête lors de l'interprétation du clustering : un regroupement de ces quatre gouvernorats refléterait la géographie autant que le climat.

7. Format de stockage

Forme	Taille	Versionné
24 CSV bruts (<code>raw_*.csv</code>)	~308 Mo	Non
CSV combiné	308 Mo	Non — au-delà de la limite GitHub de 100 Mo
Parquet zstd	42,1 Mo	Oui

Le Parquet divise le volume par 7,3 et se lit nativement par DuckDB, sans import préalable. Les données étant publiques, rien n'impose de les exclure du dépôt — contrairement aux projets précédents où la confidentialité l'interdisait.

8. Source de production

L'application déployée ne peut pas utiliser l'archive ERA5, qui accuse environ cinq jours de retard. Elle interroge l'API forecast api.open-meteo.com/v1/forecast, qui fournit les 168 dernières heures observées.

Les 31 variables y sont disponibles avec les mêmes unités. Mais les deux sources **ne coïncident pas exactement** — l'écart mesuré et ses conséquences sur le choix des variables sont documentés dans [docs/conception/2026-07-26-conception-projet.md](#), section 7.3.

9. Limites du jeu de données

- **Un point par gouvernorat.** Les gouvernorats étendus du sud ont une variabilité interne que ce point unique ne capture pas.
- **Réanalyse, pas mesure.** Les valeurs proviennent d'un modèle, non de stations. Les extrêmes en particulier peuvent être lissés.
- **7,5 ans d'historique.** Suffisant pour la variabilité saisonnière et interannuelle courante, insuffisant pour caractériser des événements rares ou une tendance climatique.

- **Chef-lieu comme proxy du gouvernorat.** Choix pratique qui ignore la diversité intra-gouvernorat, notamment entre littoral et intérieur.