

# 3 — Planning

Auteur : Ahmed Ben Arfa  
Projet : Tunisia Weather Prediction  
Date : juillet 2026

Découpage en cinq phases. Les durées sont indicatives et supposent un travail à temps partagé.

## Vue d'ensemble

Diagramme (rendu graphiquement dans la version Markdown du document) :

```
gantt
    dateFormat YYYY-MM-DD
    axisFormat %d/%m
    title Phases du projet

    section Donnees
    Extraction Open-Meteo      :done, ext, 2026-07-25, 2d
    Conception                 :done, conc, 2026-07-26, 1d
    Controles qualite et EDA   :active, eda, 2026-07-27, 4d

    section Entrepot
    Schema en etoile DuckDB    :dw, after eda, 4d
    Pont Supabase              :sb, after dw, 2d
    Rapport Power BI           :bi, after dw, 5d

    section Analyse
    Data mining (ACP + clustering) :dm, after dw, 4d

    section Modelisation
    Features et baselines      :feat, after dm, 3d
    Entrainement multi-horizon :ml, after feat, 5d
    Evaluation                  :eval, after ml, 3d

    section Livraison
    Application Streamlit       :app, after eval, 5d
    Deploiement                 :dep, after app, 2d
    Rapport et presentation     :doc, after eval, 6d
```

## Phase 1 — Données

**Terminé.** Extraction des 24 gouvernorats depuis Open-Meteo, sur deux jours en raison du quota journalier. Vérification de l'intégrité : 1 585 728 lignes, aucune valeur manquante, aucun doublon, continuité horaire parfaite.

Conception du projet rédigée et validée.

**Reste à faire** : contrôles qualité automatisés (`checks.py`), correction des humidités de sol négatives, analyse exploratoire, et extension de la mesure du décalage ERA5/forecast aux 24 gouvernorats.

| Jalon                         | Critère de sortie                                   |
|-------------------------------|-----------------------------------------------------|
| Jeu de données validé         | Contrôles automatisés passants                      |
| EDA livrée                    | Notebook exécuté, contrastes régionaux caractérisés |
| Décalage train/prod quantifié | Tableau sur les 24 gouvernorats                     |

## Phase 2 — Entrepôt et restitution descriptive

Construction du schéma en étoile dans DuckDB, agrégat journalier, pont vers Supabase, puis rapport Power BI.

| Jalon                   | Critère de sortie                                     |
|-------------------------|-------------------------------------------------------|
| Schéma en étoile chargé | Volumétries conformes, requêtes de contrôle passantes |
| Supabase alimenté       | Dimension et fait journalier en ligne, sous 500 Mo    |
| Rapport Power BI        | Pages climatologie, extrêmes, précipitations          |

## Phase 3 — Data mining

ACP sur les profils climatiques agrégés, K-means, validation géographique des groupes obtenus.

**Cette phase précède la modélisation** : elle produit la variable `cluster_climatique` que les modèles utiliseront.

| Jalon                           | Critère de sortie                                |
|---------------------------------|--------------------------------------------------|
| Groupes climatiques établis     | Nombre justifié par coude et silhouette          |
| Cohérence géographique vérifiée | Les groupes correspondent à des réalités connues |
| dim_gouvernorat enrichie        | Colonne cluster_climatique chargée               |

## Phase 4 — Modélisation

Construction des variables, baselines, entraînement des trois modèles d'horizon, évaluation.

Ordre imposé : **les baselines d'abord**. Sans elles, aucun score de modèle n'est interprétable.

| Jalon                  | Critère de sortie                                        |
|------------------------|----------------------------------------------------------|
| build_features() figée | Fonction unique, testée, sans fuite temporelle           |
| Baselines mesurées     | MAE de persistance et de climatologie aux trois horizons |
| Modèles entraînés      | Ridge, Random Forest, XGBoost × 3 horizons               |
| Évaluation livrée      | Gain sur baselines, par horizon et par gouvernorat       |

## Phase 5 — Livraison

Application Streamlit, déploiement, rapport et présentation.

| Jalon                              | Critère de sortie                               |
|------------------------------------|-------------------------------------------------|
| Application fonctionnelle en local | Prévision de bout en bout depuis l'API forecast |
| Déploiement                        | URL publique accessible, secrets configurés     |
| Rapport                            | PDF complet, limites incluses                   |
| Présentation                       | Slides et démonstration prêtes                  |

---

## Points de vigilance sur le calendrier

---

- **L'extraction ne se rejoue pas à la légère.** Une ré-extraction complète coûte deux jours à cause du quota. Les données étant versionnées, elle ne devrait pas être nécessaire.
- **Le décalage train/prod se mesure tôt.** Il conditionne le choix des variables, donc toute la phase de modélisation. Le repousser ferait retravailler les features après coup.
- **Les baselines avant les modèles.** Entraîner d'abord et comparer ensuite conduit presque toujours à surestimer l'apport du modèle.
- **L'application dépend de `build_features()`.** Toute modification tardive de cette fonction impose de réentraîner les trois modèles.