

3 — Planning

Auteur : Ahmed Ben Arfa
Projet : Tunisia Weather Prediction
Date : juillet 2026

Découpage en cinq phases. Les durées sont indicatives et supposent un travail à temps partagé.

Vue d'ensemble

Diagramme (rendu graphiquement dans la version Markdown du document) :

```
gantt
    dateFormat YYYY-MM-DD
    axisFormat %d/%m
    title Phases du projet

    section Donnees
    Extraction Open-Meteo      :done, ext, 2026-07-25, 2d
    Conception                 :done, conc, 2026-07-26, 1d
    Controles qualite et EDA   :active, eda, 2026-07-27, 4d

    section Entrepot
    Schema en etoile DuckDB    :dw, after eda, 4d
    Pont Supabase              :sb, after dw, 2d
    Rapport Power BI           :bi, after dw, 5d

    section Analyse
    Data mining (ACP + clustering) :dm, after dw, 4d

    section Modelisation
    Features et baselines      :feat, after dm, 3d
    Entrainement multi-horizon :ml, after feat, 5d
    Evaluation                 :eval, after ml, 3d

    section Livraison
    Application Streamlit      :app, after eval, 5d
    Deploiement                :dep, after app, 2d
    Rapport et presentation    :doc, after eval, 6d
```

Phase 1 — Données

Terminé. Extraction des 24 gouvernorats depuis Open-Meteo, sur deux jours en raison du quota journalier. Vérification de l'intégrité : 1 585 728 lignes, aucune valeur manquante, aucun doublon, continuité horaire parfaite.

Conception du projet rédigée et validée.

Reste à faire : contrôles qualité automatisés ([checks.py](#)), correction des humidités de sol négatives, analyse exploratoire, et extension de la mesure du décalage ERA5/forecast aux 24

gouvernorats.

Jalon	Critère de sortie
Jeu de données validé	Contrôles automatisés passants
EDA livrée	Notebook exécuté, contrastes régionaux caractérisés
Décalage train/prod quantifié	Tableau sur les 24 gouvernorats

Phase 2 — Entrepôt et restitution descriptive

Construction du schéma en étoile dans DuckDB, agrégat journalier, pont vers Supabase, puis rapport Power BI.

Jalon	Critère de sortie
Schéma en étoile chargé	Volumétries conformes, requêtes de contrôle passantes
Supabase alimenté	Dimension et fait journalier en ligne, sous 500 Mo
Rapport Power BI	Pages climatologie, extrêmes, précipitations

Phase 3 — Data mining

ACP sur les profils climatiques agrégés, K-means, validation géographique des groupes obtenus.

Cette phase précède la modélisation : elle produit la variable `cluster_climatique` que les modèles utiliseront.

Jalon	Critère de sortie
Groupes climatiques établis	Nombre justifié par coude et silhouette
Cohérence géographique vérifiée	Les groupes correspondent à des réalités connues
dim_gouvernorat enrichie	Colonne cluster_climatique chargée

Phase 4 — Modélisation

Construction des variables, baselines, entraînement des trois modèles d'horizon, évaluation.

Ordre imposé : **les baselines d'abord**. Sans elles, aucun score de modèle n'est interprétable.

Jalon	Critère de sortie
build_features() figée	Fonction unique, testée, sans fuite temporelle
Baselines mesurées	MAE de persistance et de climatologie aux trois horizons
Modèles entraînés	Ridge, Random Forest, XGBoost × 3 horizons
Évaluation livrée	Gain sur baselines, par horizon et par gouvernorat

Phase 5 — Livraison

Application Streamlit, déploiement, rapport et présentation.

Jalon	Critère de sortie
Application fonctionnelle en local	Prévision de bout en bout depuis l'API forecast
Déploiement	URL publique accessible, secrets configurés
Rapport	PDF complet, limites incluses
Présentation	Slides et démonstration prêtes

Points de vigilance sur le calendrier

- **L'extraction ne se rejoue pas à la légère.** Une ré-extraction complète coûte deux jours à cause du quota. Les données étant versionnées, elle ne devrait pas être nécessaire.
- **Le décalage train/prod se mesure tôt.** Il conditionne le choix des variables, donc toute la phase de modélisation. Le repousser ferait retravailler les features après coup.
- **Les baselines avant les modèles.** Entraîner d'abord et comparer ensuite conduit presque toujours à surestimer l'apport du modèle.
- **L'application dépend de `build_features()`.** Toute modification tardive de cette fonction impose de réentraîner les trois modèles.