

Documentation technique — Phase ETL et analyse exploratoire

Auteur : Ahmed Ben Arfa

Projet : Tunisia Weather Prediction

Phase : 01 — Extraction, contrôles, nettoyage, exploration

Date : juillet 2026

1. Objectif de la phase

Constituer un jeu de données horaire fiable pour les 24 gouvernorats tunisiens, en établir la qualité par des contrôles automatisés, corriger les anomalies identifiées, et déterminer **quelles variables sont utilisables en production**.

Ce dernier point est la contribution principale de la phase. Le modèle s'entraînera sur la réanalyse ERA5 mais prédira à partir de l'API forecast : une variable dont ces deux sources divergent propagerait son biais dans toutes ses variables dérivées, et le modèle se dégraderait en production sans que rien ne l'annonce en validation.

2. Architecture des modules

```
01_etl/  
  config.py           Chemins, plages physiques admissibles  
  extract_openmeteo.py Extraction ERA5, gestion du quota  
  build_parquet.py    Conversion CSV -> Parquet compressé  
  checks.py           Contrôles de qualité, sans effet de bord  
  clean.py            Corrections des anomalies connues  
  run_etl.py          Orchestrateur  
  skew_analysis.py    Comparaison archive / forecast  
  notebooks/  
    _build_eda.py      Générateur du notebook  
    01_eda.ipynb       Analyse exploratoire, génère  
  tests/  
    test_checks.py     7 tests  
    test_clean.py      5 tests  
    test_skew.py       4 tests
```

Le principe directeur est la séparation entre **fonctions pures** et **effets de bord**. `checks.py` et `clean.py` ne lisent aucun fichier, n'affichent rien et ne lèvent aucune exception : ils reçoivent un tableau et retournent un résultat. C'est l'orchestrateur qui décide quoi en faire. Cette séparation rend les modules testables sur des données synthétiques, sans réseau ni fichier.

Le notebook est **généré** par un script versionné. Il ne s'édite jamais à la main : toute correction passe par `_build_eda.py`, puis régénération. Les différences Git restent lisibles et le résultat est reproductible.

3. Extraction des données

3.1 Source

Open-Meteo, API d'archive archive-api.open-meteo.com, qui restitue la réanalyse ERA5 du ECMWF produite dans le cadre du programme Copernicus.

Une réanalyse n'est pas un relevé de station : c'est la sortie d'un modèle atmosphérique assimilant les observations disponibles pour reconstituer un état cohérent de l'atmosphère sur une grille régulière.

3.2 La contrainte de quota

Le quota Open-Meteo n'est pas un compte de requêtes mais un **volume pondéré** :

```
poids = (nb_variables / 10) x (nb_jours / 14)
```

Une requête de ce projet — 31 variables sur 7,5 ans — pèse à elle seule **environ 610 appels**. Les 24 gouvernorats totalisent ~14 600 appels pour un plafond gratuit de 10 000 par jour : **l'extraction complète ne tient pas dans une journée**.

Trois plafonds se superposent : 600 appels par minute, 5 000 par heure, 10 000 par jour. Un backoff exponentiel classique échoue : il retente avant la réouverture de la fenêtre et épuise ses essais dans le vide.

Le script lit donc le motif exact renvoyé dans le corps de la réponse 429 :

Motif renvoyé	Réaction
Minutely ... limit exceeded	attente de 65 s
Hourly ... limit exceeded	attente jusqu'à l'heure pleine suivante
Daily ... limit exceeded	arrêt propre, liste des gouvernorats restants

Il **reprend là où il s'est arrêté** : tout gouvernorat dont le fichier existe déjà est relu depuis le disque au lieu d'être retéléchargé.

Le **quota journalier se réinitialise à minuit UTC**, ce que la documentation Open-Meteo ne précise pas. Le comportement a été établi empiriquement : blocage à 19:22 UTC, requêtes acceptées à nouveau à 03:58 UTC le lendemain.

L'extraction s'est déroulée sur deux jours — 21 gouvernorats le premier, les 3 derniers le lendemain matin.

3.3 Format de stockage

Forme	Taille	Versionnée
24 CSV bruts	~308 Mo	Non — redondants
CSV combiné	308 Mo	Non — dépasse la limite GitHub de 100 Mo
Parquet zstd	42,1 Mo	Oui

Le Parquet divise le volume par 7,3 et se lit nativement par DuckDB, sans import préalable. Les données Open-Meteo étant publiques (licence CC BY 4.0), rien n'imposait de les exclure du dépôt.

3.4 Jeu obtenu

Caractéristique	Valeur
Lignes	1 585 728
Colonnes	36
Gouvernorats	24
Heures par gouvernorat	66 072
Période	2019-01-01 00:00 → 2026-07-15 23:00
Fuseau	Africa/Tunis

4. Contrôles de qualité

4.1 Les cinq contrôles

Contrôle	Ce qu'il vérifie
verifier_completude	Aucune valeur manquante
verifier_doublons	Unicité du couple (gouvernorat, heure)
verifier_continuite_horaire	Chaque série avance d'exactly une heure
verifier_plages_physiques	24 variables dans des bornes admissibles
verifier_decalage_groupe	Un décalage a bien été calculé par gouvernorat

Les plages physiques sont volontairement larges : l'objectif est l'aberration franche, pas la valeur rare. Une température de 55 °C serait signalée, une de 48 °C ne le serait pas — et c'est voulu, puisque le maximum réel du jeu atteint 50,2 °C.

4.2 Le contrôle qui compte pour la suite

`verifier_decalage_groupe` mérite une explication. Le jeu empile **24 séries parallèles** dans un même tableau. Un décalage global contamine les premières heures de chaque série avec les dernières de la précédente :

```
# CORRECT
df.groupby("gouvernorat")["temperature_2m"].shift(24)

# FAUX : les premieres heures de Ben Arous recuperent
# les dernieres heures d'Ariana
df["temperature_2m"].shift(24)
```

L'erreur est **silencieuse** : aucune exception n'est levée, seules les valeurs aux frontières entre gouvernorats sont fausses. Sur 24 séries et 168 heures de profondeur maximale, cela représente environ 4 000 lignes erronées noyées dans 1,58 million.

Le contrôle vérifie qu'un décalage groupé laisse exactement **horizon** valeurs manquantes en tête de chaque série. Il resservira en phase 06 pour valider la fonction de construction des variables.

4.3 Résultats sur le jeu réel

Contrôle	Résultat
Complétude	0 valeur manquante sur 1 585 728 × 36
Doublons	0
Continuité horaire	Tous les intervalles valent exactement 1 h
Nombre de gouvernorats	24, avec 66 072 heures chacun

Contrôle	Résultat
Plages physiques	Une seule famille d'anomalies

La continuité parfaite mérite d'être soulignée : sur les 66 071 intervalles de chaque série, aucun ne diffère d'une heure. Aucun trou, aucune heure dupliquée. La Tunisie n'appliquant pas l'heure d'été, il n'y a pas non plus d'artefact de changement d'heure — un problème classique sur des séries horaires.

5. Anomalies identifiées et traitement

5.1 Humidités de sol négatives

`soil_moisture_*` descendait à **-0,013 m³/m³**, ce qui est physiquement impossible : une teneur en eau volumique ne peut pas être négative.

Couche	Lignes concernées	Part
soil_moisture_0_to_7cm	493	0,031 %
soil_moisture_7_to_28cm	460	0,029 %
soil_moisture_28_to_100cm	428	0,027 %

Les cas se concentrent sur les gouvernorats arides du sud — Tozeur, Kébili, Gabès, Médenine, Tataouine, Gafsa, Sidi Bouzid, Sfax. Il s'agit d'un artefact numérique de la réanalyse sur sols très secs, où la grandeur oscille autour de zéro.

Traitement : troncature à zéro par `clean.py`. L'ampleur (0,03 %) et la nature de l'artefact rendent toute autre correction inutilement sophistiquée.

5.2 Redondance entre rain et precipitation

Les deux colonnes ne diffèrent que sur **144 lignes** — exactement celles où il neige. Leur corrélation atteint **1,000** après arrondi.

Traitement : aucun au niveau des données. C'est une décision de modélisation, prise en phase 06 : une seule des deux entrera dans le modèle.

5.3 Points de grille partagés

Trois paires de gouvernorats partagent la même latitude de grille : Tunis/Manouba, Beja/Ben Arous, Zaghuan/Nabeul. Leurs longitudes diffèrent, donc les points restent distincts, mais la résolution ERA5 ne sépare pas finement des chefs-lieux voisins.

Les quatre gouvernorats du Grand Tunis occupent des points quasi confondus. **Conséquence à retenir pour la phase 04** : un regroupement de ces quatre-là au clustering traduirait la proximité géographique autant que la similarité climatique, et ne devra pas être présenté comme une découverte.

6. Cohérence entre source d'entraînement et source de production

6.1 Le problème

Le modèle s'entraînera sur ERA5 mais prédira à partir de l'API forecast, qui provient d'un modèle de prévision opérationnel. Un biais systématique sur une variable se propagerait dans tous ses décalages et fenêtres glissantes.

6.2 Protocole

Pour chaque variable, sur les heures communes aux deux sources et sur les 24 gouvernorats — 1 872 heures par gouvernorat :

- **biais moyen** : l'écart systématique entre les deux sources ;
- **MAE** : l'ampleur moyenne du désaccord ;
- **MAE / σ** : ce désaccord rapporté à la variabilité propre de la variable, seule grandeur comparable entre des unités différentes.

6.3 Résultats

Variable	Biais	MAE	MAE/ σ
soil_moisture_* (3 couches)	0,000	0,000	0,000
terrestrial_radiation	+0,002	0,129	0,000
soil_temperature_* (3 couches)	-0,023	0,077	0,012 - 0,021
shortwave_radiation	+2,800	16,342	0,047
rain	-0,013	0,014	0,070
precipitation	-0,007	0,016	0,083
pressure_msl	-0,224	0,350	0,088
et0_fao_evapotranspiration	-0,003	0,027	0,103
direct_radiation	+6,846	29,361	0,108
direct_normal_irradiance	+11,665	44,349	0,141
temperature_2m	-0,146	0,878	0,152
diffuse_radiation	-4,046	14,743	0,158
apparent_temperature	+0,126	1,038	0,164
— seuil 0,20 —			
vapour_pressure_deficit	-0,082	0,286	0,235
cloud_cover_high	+0,331	9,496	0,266
relative_humidity_2m	+2,155	5,754	0,295
dew_point_2m	+0,539	1,538	0,392
cloud_cover	+8,690	15,994	0,437
wind_gusts_10m	-2,920	5,383	0,457
wind_speed_10m	-0,229	2,608	0,458
cloud_cover_mid	+7,937	10,353	0,541
surface_pressure	-0,503	2,609	0,669
cloud_cover_low	+3,952	4,244	0,671

6.4 Choix du seuil

Le classement présente une rupture nette entre **0,164 et 0,235** — le saut le plus large de la zone. Le seuil est placé à **0,20** dans cet intervalle : il découle de la distribution observée, il n'est pas un chiffre rond posé d'avance. **17 variables sur 31 sont retenues.**

6.5 Deux résultats notables

surface_pressure est écartée quand pressure_msl est retenue. Un rapport de 0,669 contre 0,088. L'explication est physique : la pression de surface dépend de l'altitude du relief telle que chaque modèle la représente, et les deux modèles ne partagent pas le même relief. La pression ramenée au niveau de la mer, elle, est normalisée — d'où son excellent accord. Sans cette mesure, `surface_pressure` serait entrée dans le modèle.

Le biais de température est bien plus faible qu'estimé initialement. $-0,146$ °C sur les 24 gouvernorats, contre $-0,77$ °C lors d'une mesure préliminaire sur Tunis seul. Tunis n'était pas représentatif, et l'alarme initiale était exagérée.

Les variables de sol et le rayonnement terrestre sont **identiques au millième** entre les deux sources. Pour le rayonnement terrestre c'est attendu : il est purement astronomique, calculé à partir de la géométrie Soleil-Terre, pas simulé.

6.6 Limites de la mesure

Couverture saisonnière partielle. L'API forecast ne remonte qu'à 92 jours : la comparaison ne couvrira jamais l'hiver, et les biais mesurés en saison chaude pourraient différer en saison froide.

Variables sans variance. `snowfall` ressort indéterminée — il n'a pas neigé sur la fenêtre, son écart-type est nul et le rapport indéfini.

Variables circulaires. Les MAE sur `wind_direction_10m` et `wind_direction_100m` ne sont pas interprétables : 359° et 1° sont voisins mais donnent un écart de 358. Ces deux variables sont écartées par ailleurs, mais leur valeur ne constitue pas une mesure valide.

7. Analyse exploratoire

7.1 Contrastes régionaux

La Tunisie s'étend sur près de 900 km, du littoral méditerranéen aux portes du Sahara. Le gradient nord-sud est le fait structurant du jeu.

Précipitations annuelles moyennes (2019-2025) : de **525 mm à Bizerte** à **83 mm à Tozeur**, soit un rapport de **1 à 6**.

Température moyenne : de $17,0$ °C au Kef à $22,8$ °C à Tozeur.

Le classement thermique n'est pas purement latitudinal. Les gouvernorats les plus frais — Kef et Kasserine — sont aussi les plus élevés, à 637 m et 674 m. Bizerte présente le minimum le plus doux malgré sa position la plus au nord, effet modérateur de la mer, tandis que Sidi Bouzid et Kasserine descendent sous -3 °C.

Conséquence pour la modélisation : latitude, longitude et altitude portent tous trois de l'information. Ce sont ces variables statiques qui permettront à un modèle global unique de distinguer les gouvernorats.

7.2 Structure temporelle

Deux saisonnalités coexistent : un cycle diurne de 24 heures et un cycle annuel de 8 766 heures.

C'est la contrainte centrale de la phase 05. SARIMA ne gère qu'une seule période saisonnière, et une période de 8 766 est numériquement infaisable — l'espace d'états atteindrait des dimensions

hors de portée. D'où le recours prévu aux termes de Fourier en régresseurs exogènes.

L'amplitude diurne varie fortement entre littoral et intérieur continental, ce qui recoupe le contraste climatique attendu.

7.3 Distributions

Variable	Asymétrie	Aplatissement
snowfall	234,73	69 693,87
rain	18,39	528,71
precipitation	18,37	527,02
cloud_cover_low	3,10	9,04
surface_pressure	-1,33	1,02

snowfall n'est pas une variable exploitable : 144 heures de neige sur 1,58 million donnent une asymétrie de 234 et un aplatissement de près de 70 000. Elle était déjà écartée faute de variance dans la fenêtre de comparaison ; ces chiffres le confirment indépendamment.

Les précipitations suivent avec une asymétrie de 18,4 — attendu, puisqu'il ne pleut pas la plupart des heures et que l'intensité peut être forte quand il pleut. Une telle asymétrie écarte toute hypothèse de normalité.

La température est **bimodale**, les deux modes correspondant aux saisons et non à deux populations distinctes. La pression est la seule variable proche d'une gaussienne.

La dispersion des températures de sol **décroît nettement avec la profondeur** : le sol profond filtre les variations rapides et porte l'inertie thermique saisonnière — un signal potentiellement précieux pour la prévision.

7.4 Corrélations entre variables retenues

14 paires dépassent 0,90, regroupées en trois familles.

Paire	Corrélation
precipitation ↔ rain	1,000
direct_radiation ↔ shortwave_radiation	0,982
apparent_temperature ↔ temperature_2m	0,975
shortwave_radiation ↔ terrestrial_radiation	0,971
soil_temperature_0_to_7cm ↔ temperature_2m	0,964
apparent_temperature ↔ soil_temperature_0_to_7cm	0,951
et0_fao_evapotranspiration ↔ shortwave_radiation	0,946
diffuse_radiation ↔ terrestrial_radiation	0,943
soil_temperature_28_to_100cm ↔ soil_temperature_7_to_28cm	0,935
direct_radiation ↔ et0_fao_evapotranspiration	0,933
direct_normal_irradiance ↔ direct_radiation	0,932
direct_normal_irradiance ↔ shortwave_radiation	0,928
direct_radiation ↔ terrestrial_radiation	0,916
et0_fao_evapotranspiration ↔ terrestrial_radiation	0,914

Conséquences directes pour la phase 06.

Le groupe rayonnement est le plus lourd : cinq variables retenues se recoupant à plus de 0,91. Leur construire à chacune huit décalages et trois fenêtres glissantes produirait **environ 55 colonnes portant l'information d'une dizaine**. Un ou deux représentants suffiront.

La colinéarité rend par ailleurs les coefficients d'une régression ordinaire instables — de petites variations des données produisent de grands changements de coefficients. C'est exactement le problème que traitent Ridge et Lasso : leur comparaison avec la régression simple devient un résultat, et non un passage obligé.

`soil_temperature_0_to_7cm` corrèle à 0,964 avec la température de l'air, ce qui est logique en surface. Les couches profondes décrochent, et c'est précisément leur intérêt : elles portent une inertie que l'air ne porte pas.

8. Tests

16 tests automatisés, exécutés par `pytest tests/ -v`.

Fichier	Tests	Portée
<code>test_checks.py</code>	7	Chaque contrôle sur jeu valide et jeu dégradé
<code>test_clean.py</code>	5	Correction, non-modification de l'origine, journal
<code>test_skew.py</code>	4	Calcul des métriques, hors réseau

Tous s'appuient sur des données **synthétiques** construites dans le test : ni fichier, ni réseau, exécution en moins d'une seconde.

Le test le plus important est `test_decalage_global_detecte_comme_faux` : il construit deux séries, applique un décalage global, et vérifie que le contrôle le refuse. C'est le garde-fou contre le bug silencieux décrit en 4.2.

Non couvert : la fonction `recuperer_forecast` de `skew_analysis.py`, qui touche au réseau. Sa logique de reprise sur erreur — distinguant un 429 de quota d'un 5xx transitoire — a été ajoutée après un échec réel en cours d'exécution, mais n'a pas été éprouvée par un test.

9. Livrables de la phase

Livable	Contenu
<code>data/tunisia_weather_clean.parquet</code>	1 585 728 lignes, nettoyées, 42,1 Mo
<code>data/skew_era5_forecast.csv</code>	Décalage par gouvernorat et par variable
<code>01_etl/notebooks/01_eda.ipynb</code>	45 cellules, 8 figures, exécuté
<code>tests/</code>	16 tests

10. Conséquences pour la suite

Phase 02 — entrepôt. Le schéma en étoile part de `tunisia_weather_clean.parquet`, pas du fichier brut.

Phase 04 — data mining. Le clustering doit tenir compte de l'artefact du Grand Tunis, dont les quatre gouvernorats partagent des points de grille quasi confondus.

Phase 05 — séries temporelles. Les deux saisonnalités identifiées imposent le recours aux termes de Fourier, SARIMA seul étant structurellement insuffisant.

Phase 06 — modélisation. Les 17 variables retenues constituent le point de départ. Les groupes colinéaires identifiés en 7.4 réduiront encore ce nombre. Le garde-fou `verifier_decalage_groupe` validera la construction des variables.

11. Limites assumées

- **La comparaison inter-sources ne couvre pas l'hiver** — l'API forecast ne remonte qu'à 92 jours.
- **Un point par gouvernorat.** Les gouvernorats étendus du sud ont une variabilité interne que leur chef-lieu ne capture pas.
- **ERA5 est une réanalyse, pas une mesure de station.** Les extrêmes peuvent être lissés.
- **Les contrôles de plage détectent l'aberration franche, pas la valeur plausible mais fausse.** Aucun contrôle automatisé ne peut faire mieux sans source de vérité indépendante.
- **7,5 ans d'historique** — suffisant pour la variabilité saisonnière et interannuelle courante, insuffisant pour des événements rares ou une tendance climatique.